Visualização de Dados
com ggplot2
Folha de Referência

RStudio®

Basics

ggplot2 é baseado na **gramática de gráficos**, a ideia é que você possa construir qualquer gráfico com alguns poucos componentes básicos: um conjunto de **dados**, um conjunto de **geoms**— marcações visuais que representam pontos de dados, e um **sistema de coordenadas**.

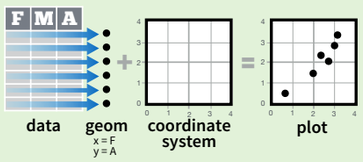

Para mostrar os valores dos dados, as variáveis são mapeadas para propriedades estéticas do geom como **tamanho**, **cor**, e locais **x** e **y**.

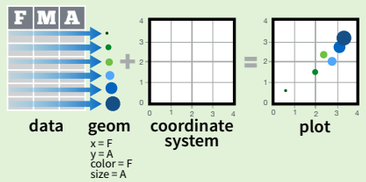

Construa um gráfico com **ggplot()** ou **qplot()**.

ggplot(data = mpg, **aes(**x = cty, y = hwy**))**

Começa um gráfico que você termina adicionando camadas a ele. Não tem valores padrões, mas permite maior controle do que qplot().

dados

```
ggplot(mpg, aes(hwy, cty)) +
 geom_point(aes(color = cyl)) +
 geom_smooth(method ="lm") +
 coord_cartesian() +
 scale_color_gradient() +
 theme_bw()
```

adiciona camadas com +

camada = geom + stat padrão + mapeamentos específicos da camada

elementos adicionais

Adiciona uma nova camada a um gráfico com a funções **geom_*()** ou **stat_*()**. Cada um disponibiliza um geom, um conjunto de mapeamentos estéticos, um stat padrão e um ajuste de posição.

mapeamentos estéticos | dados | geom

qplot(x = cty, y = hwy, color = cyl, data = mpg, geom = "point"**)**

Cria um gráfico completo com os dados, geom, e mapeamentos fornecidos. Possui vários valores padrões úteis.

last_plot()

Retorna o último gráfico.

ggsave("plot.png", width = 5, height = 5)

Salva o último gráfico em arquivo 5' x 5' nomeado de "plot.png" no diretório de trabalho. Define o tipo do arquivo pela extensão.

Geoms - Use um geom para representar pontos de dados e suas propriedades estéticas para representar variáveis. Cada função retorna uma camada.

Graphical Primitives

a <- ggplot(seals, aes(x = long, y = lat))
b <- ggplot(economics, aes(date, unemploy))

a + geom_blank()
(Útil para expandir os limites)

a + geom_curve(aes(yend = lat + delta_lat, xend = long + delta_long, curvature = z**))**
x, xend, y, yend, alpha, angle, color, curvature, linetype, size

b + geom_path(lineend="butt", linejoin="round', linemitre=1**)**
x, y, alpha, color, group, linetype, size

b + geom_polygon(aes(group = group)**)**
x, y, alpha, color, fill, group, linetype, size

a + geom_rect(aes(xmin = long, ymin = lat, xmax= long + delta_long, ymax = lat + delta_lat)**)**
xmax, xmin, ymax, ymin, alpha, color, fill, linetype, size

b + geom_ribbon(aes(ymin=unemploy - 900, ymax=unemploy + 900)**)**
x, ymax, ymin, alpha, color, fill, group, linetype, size

a + geom_segment(aes(yend=lat + delta_lat, xend = long + delta_long)**)**
x, xend, y, yend, alpha, color, linetype, size

a + geom_spoke(aes(yend = lat + delta_lat, xend = long + delta_long)**)**
x, y, angle, radius, alpha, color, linetype, size

Uma variável

Contínua

c <- ggplot(mpg, aes(hwy))

c + geom_area(stat = "bin")
x, y, alpha, color, fill, linetype, size
a + geom_area(aes(y = ..density..), stat = "bin")

c + geom_density(kernel = "gaussian"**)**
x, y, alpha, color, fill, group, linetype, size, weight

c + geom_dotplot()
x, y, alpha, color, fill

c + geom_freqpoly()
x, y, alpha, color, group, linetype, size
a + geom_freqpoly(aes(y = ..density..))

c + geom_histogram(binwidth = 5**)**
x, y, alpha, color, fill, linetype, size, weight
a + geom_histogram(aes(y = ..density..))

Discreta

d <- ggplot(mpg, aes(fl))

d + geom_bar()
x, alpha, color, fill, linetype, size, weight

Duas Variáveis

Contínua X, Contínua Y

e <- ggplot(mpg, aes(cty, hwy))

e + geom_label(aes(label = cty), nudge_x = 1, nudge_y = 1, check_overlap = TRUE**)**
x, y, label, alpha, angle, color, family, fontface, hjust, lineheight, size, vjust

e + geom_jitter(height = 2, width = 2**)**
x, y, alpha, color, fill, shape, size

e + geom_point()
x, y, alpha, color, fill, shape, size, stroke

e + geom_quantile()
x, y, alpha, color, group, linetype, size, weight

e + geom_rug(sides = "bl"**)**
x, y, alpha, color, linetype, size

e + geom_smooth(method = lm**)**
x, y, alpha, color, fill, group, linetype, size, weight

e + geom_text(aes(label = cty), nudge_x = 1, nudge_y = 1, check_overlap = TRUE**)**
x, y, label, alpha, angle, color, family, fontface, hjust, lineheight, size, vjust

Discreta X, Contínua Y

f <- ggplot(mpg, aes(class, hwy))

f + geom_bar(stat = "identity")
x, y, alpha, color, fill, linetype, size, weight

f + geom_boxplot()
x, y, lower, middle, upper, ymax, ymin, alpha, color, fill, group, linetype, shape, size, weight

f + geom_dotplot(binaxis = "y", stackdir = "center"**)**
x, y, alpha, color, fill, group

f + geom_violin(scale = "area"**)**
x, y, alpha, color, fill, group, linetype, size, weight

Discreta X, Discreta Y

g <- ggplot(diamonds, aes(cut, color))

g + geom_count()
x, y, alpha, color, fill, shape, size, stroke

Distribuição Contínua Bivariada

h <- ggplot(diamonds, aes(carat, price))

h + geom_bin2d(binwidth = c(0.25, 500)**)**
x, y, alpha, color, fill, linetype, size, weight

h + geom_density2d()
x, y, alpha, colour, group, linetype, size

h + geom_hex()
x, y, alpha, colour, fill, size

Função Contínua

i <- ggplot(economics, aes(date, unemploy))

i + geom_area()
x, y, alpha, color, fill, linetype, size

i + geom_line()
x, y, alpha, color, group, linetype, size

i + geom_step(direction = "hv"**)**
x, y, alpha, color, group, linetype, size

Visualizando Erros

df <- data.frame(grp = c("A", "B"), fit = 4:5, se = 1:2)
j <- ggplot(df, aes(grp, fit, ymin = fit-se, ymax = fit+se))

j + geom_crossbar(fatten = 2**)**
x, y, ymax, ymin, alpha, color, fill, group, linetype, size

j + geom_errorbar()
x, ymax, ymin, alpha, color, group, linetype, size, width (also **geom_errorbarh()**)

j + geom_linerange()
x, ymin, ymax, alpha, color, group, linetype, size

j + geom_pointrange()
x, y, ymin, ymax, alpha, color, fill, group, linetype, shape, size

Mapas

data <- data.frame(murder = USArrests$Murder,
  state = tolower(rownames(USArrests)))
map <- map_data("state")
k <- ggplot(data, aes(fill = murder))

k + geom_map(aes(map_id = state), map = map**) + expand_limits(**x = map$long, y = map$lat**)**
map_id, alpha, color, fill, linetype, size

Três Variáveis

seals$z <- with(seals, sqrt(delta_long^2 + delta_lat^2))
l <- ggplot(seals, aes(long, lat))

l + geom_contour(aes(z = z)**)**
x, y, z, alpha, colour, group, linetype, size, weight

l + geom_raster(aes(fill = z), hjust=0.5, vjust=0.5, interpolate=FALSE**)**
x, y, alpha, fill

l + geom_tile(aes(fill = z)**)**
x, y, alpha, color, fill, linetype, size, width

Traduzido por Augusto Queiroz de Macedo • br.linkedin.com/in/augusto-queiroz-de-macedo-552b9822

Stats - An alternative way to build a layer

Alguns gráficos realizam uma **transformação** nos dados originais. Use um **stat** para escolher uma transformação comum para visualizar, e.g. **a + geom_bar(stat = "count")**

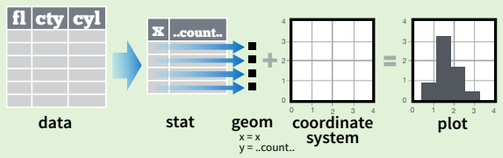

Cada stat cria variáveis adicionais que são mapeadas para a estetíca. Essas variáveeies usam uma sintaxe comum **..name..**

Ambas as funções stat e geom combinam um stat com um geom para criar uma camada, i.e. **stat_count(geom="bar")** faz o mesmo que **geom_bar(stat="count")**

função stat | mapeamento de camadas

i + stat_density2d(aes(fill = ..level..), geom = "polygon", n = 100)

geom da camada | parâmetros do stat | variável criada pela transformação

Distribuições 1D

c + stat_bin(binwidth = 1, origin = 10)
x, y | ..count.., ..ncount.., ..density.., ..ndensity..
c + stat_count(width = 1**)**
x, y, | ..count.., ..prop..
c + stat_density(adjust = 1, kernel = "gaussian"**)**
x, y, | ..count.., ..density.., ..scaled..

Distribuições 2D

e + stat_bin_2d(bins = 30, drop = TRUE**)**
x, y, fill | ..count.., ..density..
e + stat_bin_hex(bins = 30**)**
x, y, fill | ..count.., ..density..
e + stat_density_2d(contour = TRUE, n = 100**)**
x, y, color, size | ..level..
e + stat_ellipse(level = 0.95, segments = 51, type = "t"**)**

3 Variáveis

l + stat_contour(aes(z = z)**)**
x, y, z, order | ..level..
l + stat_summary_hex(aes(z = z), bins = 30, fun = mean**)**
x, y, z, fill | ..value..
l + stat_summary_2d(aes(z = z), bins = 30, fun = mean**)**
x, y, z, fill | ..value..

Comparações

f + stat_boxplot(coef = 1.5**)**
x, y | ..lower.., ..middle.., ..upper.., ..width.. , ..ymin.., ..ymax..
f + stat_ydensity(adjust = 1, kernel = "gaussian", scale = "area"**)**
x, y | ..density.., ..scaled.., ..count.., ..n.., ..violinwidth.., ..width..

Funções

e + stat_ecdf(n = 40**)**
x, y | ..x.., ..y..
e + stat_quantile(quantiles = c(0.25, 0.5, 0.75), formula = y ~ log(x), method = "rq"**)**
x, y | ..quantile..
e + stat_smooth(method = "auto", formula = y ~ x, se = TRUE, n = 80, fullrange = FALSE, level = 0.95**)**
x, y | ..se.., ..x.., ..y.., ..ymin.., ..ymax..

Propósito Geral

ggplot() + stat_function(aes(x = -3:3), fun = dnorm, n = 101, args = list(sd=0.5)**)**
x | ..x.., ..y..
e + stat_identity(na.rm = TRUE**)**
ggplot() + stat_qq(aes(sample=1:100), distribution = qt, dparams = list(df=5)**)**
sample, x, y | ..sample.., ..theoretical..
e + stat_sum()
x, y, size | ..n.., ..prop..
e + stat_summary(fun.data = "mean_cl_boot"**)**
h + stat_summary_bin(fun.y = "mean", geom = "bar"**)**
e + stat_unique()

Escalas

As **Escalas** controlam como um gráfico mapeia os valores dos dados para os valores visuais de uma estética. Para mudar o mapeamento, adicione uma escala personalizada.

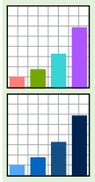

n <- b + geom_bar(aes(fill = fl)**)**
n

scale_ | estética para ajustar | escala prédefinida | argumentos específicos

n + scale_fill_manual(
values = c("skyblue", "royalblue", "blue", "navy"),
limits = c("d", "e", "p", "r"), **breaks** =c("d", "e", "p", "r"),
name = "fuel", **labels** = c("D", "E", "P", "R"))

intervalo de valores para incluir no mapeamento | título para usar na legenda/eixo | rótulo para usar na legenda/eixo | breaks para usar na legenda/eixo

Escalas de Propósito Geral

Use com qualquer estética:
alpha, color, fill, linetype, shape, size

scale_*_continuous() - mapeia valores contínuos para visuais
scale_*_discrete() - mapeia valores discretos para visuais
scale_*_identity() - usa valores dos dados **como** visuais
scale_*_manual(values = c()**)** - mapeia valores discretos para valores visuais manualmente escolhidos

Escala de local de X e Y

Use com a estética x ou y (x exposto aqui)

scale_x_date(date_labels = "%m/%d"), date_breaks = "2 weeks"**)** - trata os valores de x como datas. Ver ?strptime para o formatos.
scale_x_datetime() - trata os valores de x como data e hora. Usa os mesmos argumentos que scale_x_date().
scale_x_log10() - Transforma x para a escala log10.
.scale_x_reverse() - Inverte a direção do eixo x.
scale_x_sqrt() - Transforma x para a escala da raiz quadrada de x.

Escalas de Cor e Preenchimento

Discreta

n <- d + geom_bar(aes(fill = fl)**)**

n + scale_fill_brewer(palette = "Blues"**)**
Para opções de paleta:
ibrary(RColorBrewer)
display.brewer.all()

n + scale_fill_grey(start = 0.2, end = 0.8, na.value = "red"**)**

Contínua

o <- c + geom_dotplot(aes(fill = ..x..)**)**

o + scale_fill_gradient(low = "red", high = "yellow"**)**

o + scale_fill_gradient2(low = "red", high = "blue", mid = "white", midpoint = 25**)**

o + scale_fill_gradientn(colours = terrain.colors(6)**)**
Também: rainbow(), heat.colors(), topo.colors(), cm.colors(), RColorBrewer::brewer.pal()

Escalas de Formato

p <- e + geom_point(aes(shape = fl, size = cyl)**)**

p + scale_shape(solid = FALSE**)**

p + scale_shape_manual(values = c(3:7)**)**
Valores de formato expostos no gráfico à direita

Manual shape values

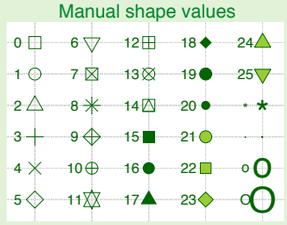

Escalas de Tamanho

p + scale_radius(range=c(1,6)**)**
p + scale_size()

p + scale_size_area(max_scale = 6**)**
Mapeia para área do círculo (não radianos)

Sistema de Coordenadas

r <- d + geom_bar()

r + coord_cartesian(xlim = c(0, 5)**)**
xlim, ylim
Sistema de coordenadas padrão

r + coord_fixed(ratio = 1/2**)**
ratio, xlim, ylim
Sistema de coordenadas com proporção fixa entre as unidades de x e y.

r + coord_flip()
xlim, ylim
Coordenadas cartersianas invertidas

r + coord_polar(theta="x",direction= 1**)**
theta, start, direction
Coordenadas polares

r + coord_trans(ytrans = "sqrt"**)**
xtrans, ytrans, limx, limy
Coordenadas cartesianas transformadas. Define xtrans e ytrans para o nome da função de janelamento.

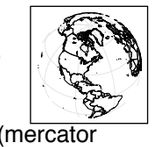

π + coord_map(projection = "ortho", orientation=c(41, -74, 0)**)**
projection, orientation, xlim, ylim
Mapeia projeções do pacote mapproj (mercator (padrão), azequalarea, lagrange, etc.)

Facetas

Facetas dividem um gráfico em sub-gráficos baseando-se em uma ou mais variáveis discretas.

t <- ggplot(mpg, aes(cty, hwy)) + geom_point()

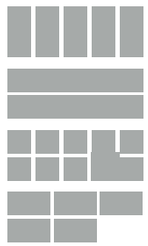

t + facet_grid(. ~ fl)
divide em colunas baseado em fl
t + facet_grid(year ~ .)
divide em linhas baseado em year
t + facet_grid(year ~ fl)
divide em linhas e colunas
t + facet_wrap(~ fl)
ajusta as facetas em um formato retangular

Defina **scales** para que os limites variem entre os eixos

t + facet_grid(drv ~ fl, scales = "free")
Ajusta os limites dos eixos x e y para facetas individuais
- **"free_x"** - ajusta os limites do eixo x
- **"free_y"** - ajusta os limites do eixo y

Defina **labeller** para ajustar os rótulos das facetas

t + facet_grid(. ~ fl, labeller = label_both)

fl: c	fl: d	fl: e	fl: p	fl: r

t + facet_grid(fl ~ ., labeller = label_bquote(alpha ^ .(fl)**))**

α^p α^r

t + facet_grid(. ~ fl, labeller = label_parsed)

c	d	e	p	r

Ajustes de Posição

Ajustes de posição definem como os geoms se localizam, evitando que ocupem o mesmo espaço.

s <- ggplot(mpg, aes(fl, fill = drv))

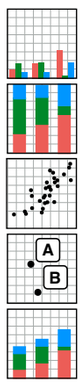

s + geom_bar(position = "dodge")
Coloca os elementos lado a lado.
s + geom_bar(position = "fill")
Empilha os elementos um sobre o outro, normaliza a altura.
e + geom_point(position = "jitter")
Adiciona um ruído aleatório para as posições X e Y de cada elemento evitando a sobreposição.
e + geom_label(position = "nudge")
Afasta os rótulos dos pontos.
s + geom_bar(position = "stack")
Empilha os elementos um sobre o outro.

Cada ajuste de posição pode ser redefinido como um ajuste de posição manual dos argumentos **width** e **height**.

s + geom_bar(position = position_dodge(width = 1))

Rótulos

t + ggtitle("New Plot Title"**)**
Adiciona um título principal sobre o gráfico
t + xlab("New X label"**)**
Muda o rótulo do eixo X
t + ylab("New Y label"**)**
Muda o rótulo do eixo Y
t + labs(title =" New title", x ="New x", y ="New y"**)**
Todos acima

Use funções scale para atualizar o rótulo das legendas

Legendas

n + theme(legend.position = "bottom"**)**
Coloca a legenda no "bottom", "top", "left", ou "right"
n + guides(fill = "none"**)**
Define o tipo da legenda para cada estética: colorbar, legend, ou none (sem legenda)
n + scale_fill_discrete(name = "Title", labels = c("A", "B", "C", "D", "E"**)**
Define o título da leganda e os rótulos com uma função scale.

Temas

r + theme_bw()
Fundo branco com linhas em grande

r + theme_gray()
fundo cinza (tema padrão)

r + theme_dark()
escuro para contraste

r + theme_classic()
r + theme_light()
r + theme_linedraw()

r + theme_minimal()
Temas mínimos
r + theme_void()
Temas vazio

Zoom

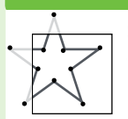

Sem recorte (preferido)
t + coord_cartesian(
xlim = c(0, 100), ylim = c(10, 20)**)**

Com recorte (remove dados não visualizados)

t + xlim(0, 100**) + ylim(**10, 20**)**
t + scale_x_continuous(limits = c(0, 100)**) + scale_y_continuous(**limits = c(0, 100)**)**

Traduzido por Augusto Queiroz de Macedo • br.linkedin.com/in/augusto-queiroz-de-macedo-552b9822